

Présentation du projet

Intitulé du projet

Symphonie des données

Formation / Parcours concerné

Master 1 Intelligence Artificielle

Intervenant référent du projet

Najib AL AWAR

Période du projet

Durée : 20 - 30 heures

Lancement : 27 Février

Fin : À détermier

Modalités pédagogiques

Projet fil rouge – Travail individuel

Modalité d'évaluation

Projet collectif avec soutenance

2. Finalité pédagogique du projet

2.1 Objectif général

Concevoir l'architecture d'une plateforme permettant de collecter, stocker, structurer et orchestrer des données (audio, images ou autres formats), afin d'alimenter un modèle d'intelligence artificielle dans une logique d'entraînement continu, tout en assurant la visualisation et le suivi du cycle de vie des données.

2.2 Objectifs pédagogiques opérationnels

À l'issue du projet, l'étudiant sera capable de :

- Concevoir une architecture de gestion de données adaptée à un projet d'IA.
- Modéliser une base de données relationnelle ou hybride (métadonnées + stockage de fichiers).
- Structurer un pipeline de circulation des données (ingestion, validation, transformation, stockage, exploitation).
- Mettre en place un mécanisme d'alimentation continue d'un modèle d'apprentissage automatique.
- Assurer la traçabilité, la versioning et la gouvernance des jeux de données.
- Visualiser les flux de données et les indicateurs liés à leur exploitation.

2.3 Conditions de réussite et exigences attendues

Prérequis nécessaires au projet :

- Connaissances fondamentales en bases de données.
- Notions de machine learning.
- Bases en développement Python ou équivalent.

Attendus en termes d'implication et de posture professionnelle :

- Travail collaboratif structuré.
- Respect des jalons et des livrables.
- Documentation claire et professionnelle.
- Justification des choix techniques.

3. Compétences professionnelles visées

Compétence 1 : Concevoir et structurer une architecture de gestion de données adaptée à un projet d'intelligence artificielle.

Compétence 2 : Mettre en œuvre un pipeline de données robuste intégrant collecte, transformation et stockage.

Compétence 3 : Assurer l'intégration continue des données dans un processus d'entraînement de modèle.

Compétence 4 : Mettre en place des outils de visualisation et de suivi des flux de données.

4. Contexte du projet

Dans un contexte professionnel simulé, les étudiants doivent concevoir une plateforme permettant à des utilisateurs d'ajouter des données (audio, images ou autres types de fichiers) via une interface dédiée.

Ces données doivent ensuite circuler à travers un pipeline structuré :

- Phase d'ingestion (upload et validation)
- Stockage des fichiers
- Enregistrement des métadonnées en base de données
- Transformation éventuelle (nettoyage, structuration, extraction de caractéristiques)
- Constitution de jeux de données exploitables
- Alimentation d'un modèle d'intelligence artificielle

L'ensemble du processus doit être traçable, versionné et visualisable depuis une interface de supervision.

Le projet s'inscrit dans une logique de cycle de vie complet des données, préalable indispensable à la phase suivante du cursus consacrée à l'optimisation et au développement avancé des modèles.

5. Livrables attendus

5.1 Production finale attendue

Les étudiants devront produire :

- Une architecture détaillée de la plateforme (schémas techniques).
- Un schéma de base de données documenté.
- Une description du pipeline de données.
- Une démonstration fonctionnelle ou prototype.
- Une documentation technique structurée.
- Une présentation orale.

Format attendu

- Rapport PDF
- Dépôt Git (code et documentation)
- Présentation (PPT ou équivalent)

Contraintes éventuelles

- Respect des bonnes pratiques de modélisation.
- Séparation claire entre stockage des fichiers et stockage des métadonnées.
- Intégration d'un mécanisme de versioning des datasets.

6. Modalités pédagogiques et accompagnement

- Travail en individuel.
- Séances d'accompagnement méthodologique.
- Revue intermédiaire des choix techniques.
- Coaching orienté architecture et data engineering.

7. Modalités d'évaluation

7.1 Critères d'évaluation

Critère 1 : Pertinence et cohérence de l'architecture proposée.

Critère 2 : Qualité de la modélisation de la base de données.

Critère 3 : Robustesse du pipeline de données.

Critère 4 : Intégration claire avec le processus d'entraînement du modèle.

Critère 5 : Qualité de la documentation et de la présentation.

7.2 Modalités d'évaluation

Modalité : Collective avec part individuelle lors de la soutenance.

Outils utilisés : Grille critériée, soutenance orale, analyse du dépôt Git.

8. Ressources mises à disposition

Ressources pédagogiques

- Supports de cours sur bases de données.
- Supports sur data engineering et pipelines.

Outils techniques

- SGBD relationnel.
- Environnement Python.
- Outils de visualisation.

Documentation professionnelle / réglementaire

- Bonnes pratiques de gouvernance des données.
- Notions de protection des données.

9. Suggestions de thématiques possibles

Les orientations ci-dessous visent à contextualiser la plateforme tout en conservant le même socle architectural : ingestion multi-format, stockage structuré, pipeline de transformation, versioning des datasets et alimentation continue d'un modèle.

9.1 Observatoire sonore urbain (contexte français)

Objectif : concevoir une plateforme permettant la collecte et la gestion de données audio issues d'environnements urbains (ambiances sonores, trafic, transports, espaces publics).

Dimensions pédagogiques mobilisées :

- Gestion de fichiers volumineux (formats audio variés).
- Stockage des métadonnées (lieu, date, durée, type d'environnement, conditions de capture).
- Mise en place d'un système de labellisation (catégories sonores).
- Constitution de jeux de données versionnés.
- Préparation d'un flux d'entraînement pour un modèle de classification audio.

Sources possibles :

- Données collectées par les étudiants dans un cadre réglementé.
- Jeux de données ouverts francophones (voix, environnement sonore).

9.2 Plateforme d'images territoriales

Objectif : développer une infrastructure permettant d'ingérer et de structurer des images liées à un territoire (mobilier urbain, signalisation, accessibilité, environnement).

Dimensions pédagogiques mobilisées :

- Gestion du stockage externe (images) et base relationnelle pour les métadonnées.
- Schémas d'annotation (tags, catégories, détection d'objets).
- Structuration des jeux d'entraînement (train/validation/test).
- Extraction et stockage de caractéristiques intermédiaires (features).
- Visualisation de la croissance et de la qualité du dataset.

Sources possibles :

- Données ouvertes issues de plateformes publiques.
- Images collectées localement dans un cadre pédagogique.

9.3 Données de mobilité et flux continus

Objectif : construire un système capable d'ingérer des données dynamiques (transports, disponibilité d'équipements, flux urbains) et de les structurer dans une base adaptée aux séries temporelles.

Dimensions pédagogiques mobilisées :

- Connexion à des API publiques.
- Planification d'ingestion automatique (batch ou quasi temps réel).
- Gestion des volumes et de l'historisation.
- Création de vues "prêtes pour l'entraînement".
- Mise en place d'indicateurs de dérive ou de variation des données.

Sources possibles :

- Portails open data français (mobilité, transport, ville intelligente).

9.4 Registre de datasets et traçabilité avancée

Objectif : concevoir une plateforme orientée gouvernance des données, centrée sur la traçabilité complète du cycle de vie des jeux de données.

Dimensions pédagogiques mobilisées :

- Versioning des datasets (snapshots immuables).
- Suivi des transformations successives (raw → cleaned → processed → training).
- Association entre jeux de données et modèles entraînés.
- Journalisation des expérimentations.
- Mise en place d'une interface de consultation et d'audit.

Ce scénario met particulièrement l'accent sur les enjeux professionnels de reproductibilité, conformité réglementaire et auditabilité.

Ces thématiques constituent des cadres applicatifs possibles. Quel que soit le domaine retenu, l'évaluation portera principalement sur :

- La qualité de l'architecture data.
- La cohérence du pipeline.
- La robustesse du modèle de données.
- La capacité à structurer un flux continu vers un modèle d'IA.
- La clarté de la visualisation du cycle de vie des données.